Miniproyecto evaluativo

Ajuste no lineal de datos por mínimos cuadrados:
Dogleg, Levenberg–Marquardt y gradiente estocástico

Curso de Métodos de Optimización — Maestría
Prof. Whady Felipe Florez

Modalidad:	individual, con datos personalizados (semilla = tu número de documento)
Entrega:	informe PDF (máximo 6 páginas + anexo) y un único script `main.py`
Fecha límite:	[fecha] **Peso en la nota:** [%]

1. Contexto y objetivo

Una pieza metálica se enfría y su temperatura se mide con un sensor que tiene inercia térmica propia. La respuesta medida es la suma de dos decaimientos exponenciales, uno rápido (el sensor) y uno lento (la pieza):

$$y(t;\boldsymbol{\theta}) = a\,e^{-b\,t} + c\,e^{-d\,t}, \qquad \boldsymbol{\theta} = (a,b,c,d)^{\top}, \tag{1}$$

con t en minutos, y el exceso de temperatura (°C), a, c amplitudes y b, d tasas de decaimiento (1/min). El modelo es **no lineal en** b **y** d.

Recibirás un archivo `datos_<documento>.csv` con $n = 150$ pares (t_i, y_i), $t \in [0, 20]$ min, con ruido gaussiano de desviación desconocida. El objetivo es **estimar** $\boldsymbol{\theta}$ minimizando

$$f(\boldsymbol{\theta}) = \tfrac{1}{2}\sum_{i=1}^{n} r_i(\boldsymbol{\theta})^2 = \tfrac{1}{2}\,\|\mathbf{r}(\boldsymbol{\theta})\|^2, \qquad r_i(\boldsymbol{\theta}) = y(t_i;\boldsymbol{\theta}) - y_i, \tag{2}$$

con tres métodos implementados **por ti** (solo `numpy`) y compararlos entre sí y con `least_squares` de `scipy.optimize`.

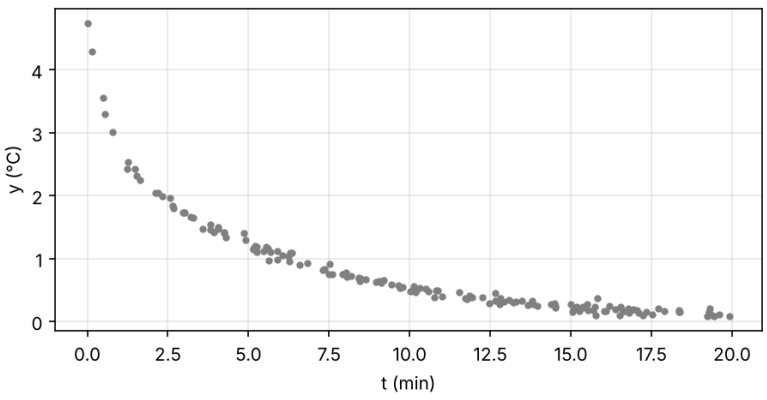


Figura 1: Ejemplo de datos (`datos_ejemplo.csv`). Los tuyos son distintos pero tienen la misma estructura.

2. Partes del proyecto

Parte A — Formulación (15 pts)

A1. Deduce la jacobiana $\mathbf{J} \in \mathbb{R}^{n\times 4}$, $J_{ij} = \partial r_i/\partial\theta_j$, y expresa $\nabla f = \mathbf{J}^\top \mathbf{r}$.

A2. Escribe la Hessiana exacta $\nabla^2 f = \mathbf{J}^\top\mathbf{J} + \sum_i r_i \nabla^2 r_i$ y explica cuándo es razonable aproximarla por $\mathbf{B} = \mathbf{J}^\top\mathbf{J}$ (Gauss–Newton). ¿Qué propiedad tiene $\mathbf{B}$ que no tiene la Hessiana exacta?

A3. Verifica tu jacobiana contra diferencias finitas y reporta el error relativo máximo (debe ser $< 10^{-6}$).

Parte B — Implementación de los tres minimizadores (35 pts)

Usa $\mathbf{g} = \mathbf{J}^\top\mathbf{r}$ y $\mathbf{B} = \mathbf{J}^\top\mathbf{J}$ en el punto actual $\boldsymbol{\theta}_k$. No está permitido llamar a `scipy` dentro de tus implementaciones; `scipy` se usa únicamente para comparar.

B1. **Dogleg (12 pts).** Región de confianza con modelo $m(\mathbf{p}) = \mathbf{g}^\top\mathbf{p} + \frac{1}{2}\mathbf{p}^\top\mathbf{B}\mathbf{p}$: paso de Cauchy, paso de Gauss–Newton, intersección de la poligonal con $\|\mathbf{p}\| = \Delta_k$ (ecuación cuadrática en τ), razón $\rho_k = \dfrac{f(\boldsymbol{\theta}_k) - f(\boldsymbol{\theta}_k + \mathbf{p}_k)}{m(\mathbf{0}) - m(\mathbf{p}_k)}$, aceptación si $\rho_k > 0$, y actualización de Δ_k (encoger si $\rho_k < 1/4$; crecer si $\rho_k > 3/4$ y $\|\mathbf{p}_k\| = \Delta_k$). **Tu código debe tratar el caso en que B es singular o casi singular** y justificar qué paso usa entonces.

B2. **Levenberg–Marquardt (12 pts).** Resuelve $(\mathbf{B} + \lambda\,\mathrm{diag}(\mathbf{B}))\mathbf{p} = -\mathbf{g}$, con una regla explícita para λ basada en ρ_k (decéla y élala tú: reduce λ si el paso se acepta, auméntalo si se rechaza). Explica por qué se escala con $\mathrm{diag}(\mathbf{B})$ en este problema.

B3. **Gradiente estocástico (11 pts).** Minilotes de tamaño m (permutación aleatoria en cada época), gradiente del lote $\frac{1}{m}\mathbf{J}_B^\top\mathbf{r}_B$, paso $\alpha_k = \alpha_0/(1 + k/k_0)$ y, opcionalmente, momentum. Debe aceptar `batch`, `lr0`, `k0`, `epocas` y `seed`.

Criterios de parada razonables: $\|\mathbf{g}\|_\infty < 10^{-6}$ o paso despreciable (Dogleg y LM); número fijo de épocas (SGD). Documenta los que uses.

Parte C — Experimentos (30 pts)

Toma como *solución de referencia* $\boldsymbol{\theta}^*$ la que entrega `least_squares(..., method="lm")` con tolerancias muy pequeñas (`xtol=ftol=gtol=1e-15`), y $f^* = f(\boldsymbol{\theta}^*)$.

C1. **Comparación (10 pts).** Desde $\boldsymbol{\theta}_0 = (1, 1, 1, 0.5)$, completa una tabla con: iteraciones (o pasos), *evaluaciones de datos*, $f(\boldsymbol{\theta}_{\text{final}})$, $\|\boldsymbol{\theta}_{\text{final}} - \boldsymbol{\theta}^*\|$ y tiempo, para Dogleg, LM, SGD y `least_squares` (`lm` y `trf`). Una *evaluación de datos* es una fila (t_i, y_i) procesada para calcular residuo y/o jacobiana: en Dogleg/LM cada iteración cuesta $\approx 2n$ (una pasada en $\boldsymbol{\theta}_k$ y otra para probar $\boldsymbol{\theta}_k + \mathbf{p}_k$); en SGD cada paso cuesta m. Grafica $(f - f^*)/f^*$ en escala semilogarítmica. **Meta para SGD:** $(f - f^*)/f^* < 5\ \%$ (ajusta α_0, k_0, m o momentum).

C2. **Sensibilidad al punto inicial (10 pts).** Ejecuta Dogleg y LM desde los seis puntos de la Tabla 1. Reporta iteraciones y f final en una tabla y dibuja las trayectorias en el plano (b, d) para al menos tres inicios. Responde: (i) ¿todos los inicios llegan al mismo f? (ii) Si alguno no lo hace, ¿el punto al que llega es un mínimo? Justifícalo con los autovalores de $\mathbf{B}$ y de la Hessiana exacta en ese punto (puedes aproximar esta última por diferencias finitas de f). (iii) ¿Qué pasa

con el inicio D y por qué el modelo tiene esa simetría? (iv) Propone una forma de eliminar esa ambigüedad al reportar $\boldsymbol{\theta}^*$.

C3. **Gradiente estocástico (10 pts).** Con $\boldsymbol{\theta}_0 = (1, 1, 1, 0.5)$ estudia: tres tamaños de lote (incluye el lote completo $m = n$); paso constante frente a decreciente; momentum (opcional). Una figura con $(f - f^*)/f^*$ frente a la época. Explica con tus datos por qué SGD es mucho más lento que LM en este problema (relaciona con el número de condición $\kappa(\mathbf{J}^\top \mathbf{J})$) y en qué tipo de problema sí sería la mejor opción.

Tabla 1: Puntos iniciales $\boldsymbol{\theta}_0 = (a, b, c, d)$ para C2.

A	B	C	D	E	F
$(1, 1, 1, 0.5)$	$(5, 5, 5, 5)$	$(1, 0.3, 1, 0.35)$	$(1, 0.1, 1, 2)$	$(3, 0.5, 0.5, 0.05)$	$(1, 1, 1, 1)$

Parte D — Incertidumbre de los parámetros (10 pts)

En $\boldsymbol{\theta}^*$ estima $\hat{\sigma}^2 = 2f^*/(n - 4)$ y la covarianza $\widehat{\mathrm{Cov}}(\boldsymbol{\theta}) = \hat{\sigma}^2(\mathbf{J}^\top \mathbf{J})^{-1}$.

D1. Reporta $\boldsymbol{\theta}^*$, desviaciones estándar e intervalos de confianza de ≈ 95 % ($\pm 1.98\,\mathrm{sd}$), la matriz de correlación y $\kappa(\mathbf{J}^\top \mathbf{J})$.

D2. ¿Qué parámetro queda peor determinado y qué par de parámetros está más correlacionado? Explica físicamente (qué información aporta la ventana $t \in [0, 20]$ sobre cada tasa).

D3. Con `datos_sinteticos` (en la plantilla) genera datos con tu $\boldsymbol{\theta}^*$ y $\sigma \in \{0.05, 0.2, 0.5\}$, reajusta con LM y muestra cómo cambian las desviaciones estándar. ¿Qué relación observas con σ?

Parte E — Informe y código (10 pts)

Informe de máximo 6 páginas (más anexo con código si lo deseas) con: formulación breve, descripción de cada algoritmo con *tus* decisiones (parámetros, reglas, criterios de parada), resultados de C y D con tablas y figuras legibles, y conclusiones. El archivo `main.py` debe reproducir todas las tablas y figuras con `python main.py datos_<documento>.csv` y semillas fijas.

3. Rúbrica

Parte	**Pts**	**Se evalúa**
A. Formulación	15	jacobiana correcta y verificada; análisis de $\mathbf{B}$ frente a la Hessiana exacta
B. Implementación	35	los tres métodos funcionan y convergen a $\boldsymbol{\theta}^*$ (Dogleg y LM) o a la meta (SGD); manejo de $\mathbf{B}$ singular; reglas de ρ_k, Δ_k y λ bien justificadas
C. Experimentos	30	tablas y figuras correctas; diagnóstico del punto estacionario no mínimo; análisis de SGD con evidencia
D. Incertidumbre	10	cálculo correcto; interpretación física; efecto de σ
E. Informe y código	10	claridad, reproducibilidad, figuras con ejes y leyendas
Total	**100**	

Bonificación (máx. +10): (+5) reducir el problema a 2 variables eliminando las amplitudes lineales a, c por mínimos cuadrados lineales en cada evaluación (*variable projection*) y comparar; (+5) imponer $b, d > 0$ mediante reparametrización $b = e^{\beta}$, $d = e^{\delta}$ y comparar.

4. Referencias sugeridas

Nocedal & Wright, *Numerical Optimization*, cap. 4 (región de confianza, dogleg) y cap. 10 (mínimos cuadrados no lineales, Levenberg–Marquardt); Bottou, Curtis & Nocedal (2018), *Optimization methods for large-scale machine learning* (SGD); y el material de las Clases 3 y 4 del curso.