Solucionario del miniproyecto

Ajuste no lineal: Dogleg, Levenberg–Marquardt y gradiente estocástico
(documento para el profesor — no distribuir)

1. Corrida de referencia

Datos generados con la semilla 2026 (`generar(2026)`, $n = 150$, $\sigma = 0.05$). Los parámetros verdaderos son $\boldsymbol{\theta}_{\text{real}} = (1.8716, 1.5420, 2.9804, 0.14612)$. El mínimo de mínimos cuadrados (referencia de `least_squares`, `lm`, tolerancias 10^{-15}) es

$$\boldsymbol{\theta}^* = (1.8701,\ 1.6937,\ 3.0204,\ 0.14709), \qquad f^* = 0.19913, \qquad \hat{\sigma} = 0.0522.$$

La suma de cuadrados esperada para ruido puro es $\frac{1}{2}n\sigma^2 = 0.1875$, así que f^* es coherente con un buen ajuste. Todo se reproduce con `python solucion_referencia.py 2026` (genera las figuras y las tablas de este documento).

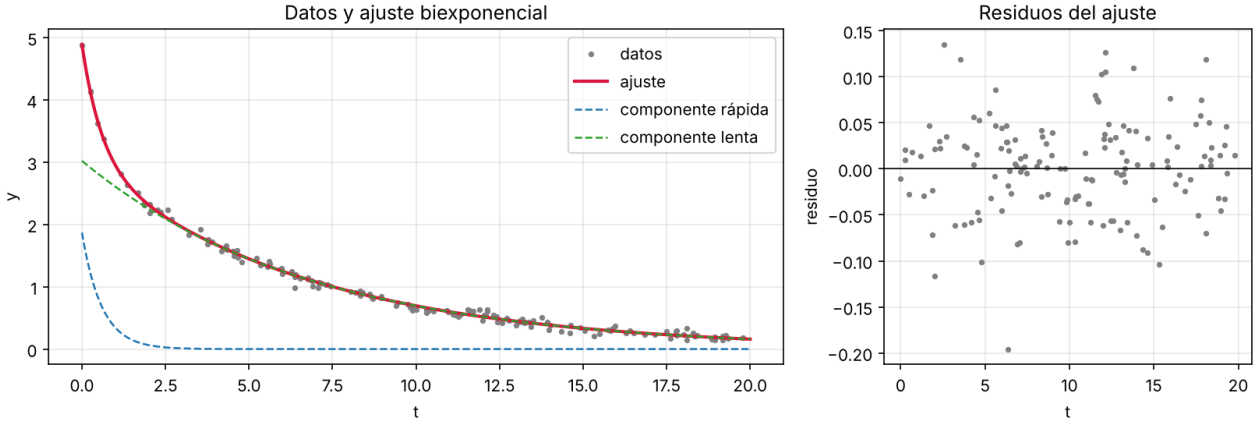


Figura 1: Datos, ajuste y componentes (izquierda); residuos sin estructura (derecha).

2. Resultados esperados

Parte A

Con $e_1 = e^{-bt}$ y $e_2 = e^{-dt}$, las columnas de $\mathbf{J}$ son $\partial r/\partial a = e_1$, $\partial r/\partial b = -a\,t\,e_1$, $\partial r/\partial c = e_2$, $\partial r/\partial d = -c\,t\,e_2$. $\mathbf{B} = \mathbf{J}^\top\mathbf{J}$ es siempre semidefinida positiva; la Hessiana exacta no (el término $\sum_i r_i \nabla^2 r_i$ puede ser indefinido y solo es despreciable si los residuos son pequeños o el modelo es casi lineal). Error relativo con diferencias finitas centrales ($h = 10^{-7}$): del orden de 10^{-9} (relativo al mayor elemento de $\mathbf{J}$).

Parte C1: comparación desde $\boldsymbol{\theta}_0 = (1, 1, 1, 0.5)$

Método	Iter./pasos	Eval. de datos	$f(\theta)$	$\|\theta - \theta^*\|$	ms
Dogleg	20	6 000	0.19913	3.7e-10	2
Levenberg–Marquardt	20	6 000	0.19913	1.9e-09	1
scipy least_squares (lm)	12	3 600	0.19913	2.0e-08	1
scipy least_squares (trf)	10	3 000	0.19913	4.8e-08	–
SGD puro, lote 16	50 000	800 000	0.20205	1.4e-01	955
SGD + momentum 0.9, lote 16	15 000	240 000	0.20178	9.9e-02	361

Dogleg y LM convergen en ≈ 20 iteraciones a $\boldsymbol{\theta}^*$ (error $< 10^{-8}$); `scipy` necesita 10–12 evaluaciones. SGD alcanza la meta del 5 % (1.5 % el puro tras 50 000 pasos, 1.3 % con momentum tras 15 000), pero con **40 a 130 veces más evaluaciones de datos** y con un error en $\boldsymbol{\theta}$ todavía de ≈ 0.1. Criterio de aceptación sugerido: Dogleg y LM con $\|\boldsymbol{\theta} - \boldsymbol{\theta}^*\| < 10^{-6}$ y $\lesssim 40$ iteraciones; SGD con $(f - f^*)/f^* < 5$ %.

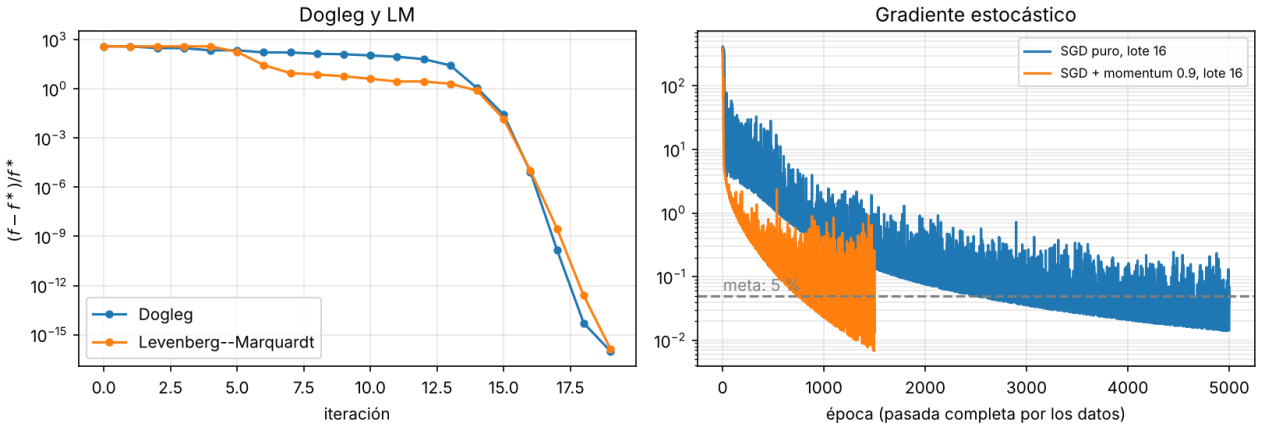


Figura 2: Convergencia. Dogleg y LM: convergencia superlineal al final. SGD: ruido de minilote y meseta en torno al 1–2 %.

Parte C2: sensibilidad al punto inicial

	θ_0	Dogleg		LM	
		iter.	f_{final}	iter.	f_{final}
A	$(1, 1, 1, 0.5)$	20	0.1991	20	0.1991
B	$(5, 5, 5, 5)$	171	2.0050	30	0.1991
C	$(1, 0.3, 1, 0.35)$	16	0.1991	21	0.1991
D	$(1, 0.1, 1, 2)$	8	0.1991	11	0.1991
E	$(3, 0.5, 0.5, 0.05)$	8	0.1991	10	0.1991
F	$(1, 1, 1, 1)$	132	2.0050	33	0.1991

Observaciones:

- **B y F con Dogleg** terminan en $f = 2.005$ en el punto $\boldsymbol{\theta} \approx (1.864, 0.178, 1.864, 0.178)$, donde $a = c$ y $b = d$: las dos exponenciales coinciden y el modelo colapsa a $2a\,e^{-bt}$. El gradiente es $\approx 10^{-6}$ (por eso Dogleg se detiene), **B** tiene **dos autovalores nulos** ($\sim 10^{-14}$) y la **Hessiana**

exacta tiene un autovalor -142: es un **punto silla**, no un mínimo. La aproximación de Gauss–Newton no ve esa curvatura negativa (es semidefinida positiva), y como $\mathbf{B}$ es singular el Dogleg solo usa el paso de Cauchy, de modo que no puede escapar y avanza lentamente.

- Desde el inicio simétrico exacto F, las iteraciones de LM también permanecen simétricas ($|a - c| = 0$) durante varias iteraciones; **LM sale del punto silla por amplificación del ruido numérico a lo largo de la dirección de curvatura negativa**, no por una garantía teórica. Con asimetría pequeña en $\boldsymbol{\theta}_0$ (p. ej. $d_0 = 1 + 10^{-4}$) ambos métodos convergen; con 10^{-2} Dogleg aún se queda cerca del silla tras 500 iteraciones. Moraleja: verificar autovalores de la Hessiana exacta al terminar y no comenzar en configuraciones simétricas.
- **Inicio D**: $(a, b) \leftrightarrow (c, d)$ intercambia los dos términos sin cambiar $y(t)$; por eso D converge a $\boldsymbol{\theta}^*$ *permutado*, (3.02, 0.147, 1.87, 1.694), con el mismo f^*. Solución: imponer la convención $b > d$ (reordenar los pares (a, b), (c, d) al reportar) o reparametrizar con $b = d + e^{\gamma}$.
- **Inicio C** ($b \approx d$) deja $\mathbf{B}$ casi singular; ambos métodos convergen sin problemas.

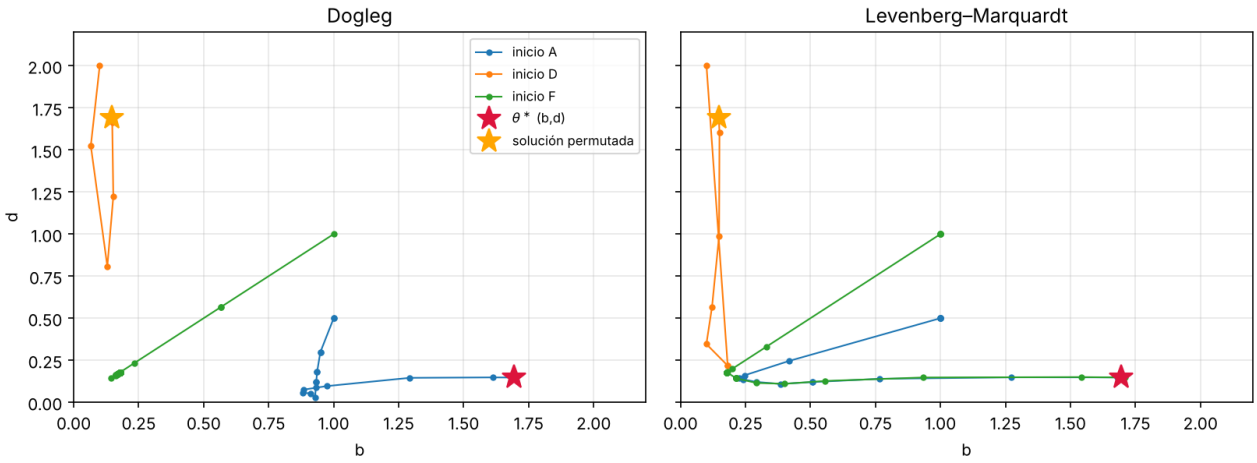


Figura 3: Trayectorias en el plano (b, d). Dogleg desde F llega al punto simétrico $b = d \approx 0.18$; LM lo atraviesa.

Parte C3: gradiente estocástico (3000 épocas, $\alpha_0 = 0.1$, $k_0 = 5000$)

Configuración	pasos	$(f - f^*)/f^*$ final
lote 150 (gradiente completo)	3 000	4.84
lote 16, paso decreciente	30 000	0.065
lote 4, paso decreciente	114 000	0.0086
lote 16, paso constante 0.1	30 000	14.5 (oscila)
lote 16, paso constante 0.02	30 000	0.097

El lote completo *no* es mejor: con las mismas épocas (igual cómputo de datos) hace 10 veces menos pasos que el lote 16. El paso constante grande oscila y no converge; uno pequeño converge pero lento; el decreciente combina ambas. Momentum $\beta = 0.9$ con $\alpha_0 = 0.01$ llega al 1.3 % en 15 000 pasos. La causa de la lentitud es el mal condicionamiento: los autovalores de $\mathbf{B} = \mathbf{J}^\top \mathbf{J}$ en $\boldsymbol{\theta}^*$ son $0.25,\ 0.98,\ 11.1,\ 5.4 \times 10^3$, es decir $\kappa = 2.1 \times 10^4$. Para el costo medio f/n el paso estable cumple $\alpha < 2n/\lambda_{\text{máx}}(\mathbf{B}) \approx 0.055$ (por eso el paso constante 0.1 oscila y 0.02 no), y la dirección de curvatura

menor se contrae solo por un factor $1 - \alpha\lambda_{\text{mín}}/n \approx 1 - 3 \times 10^{-5}$ por paso (con $\alpha = 0.02$): decenas de miles de pasos para reducir el error en ella por un factor e. Dogleg y LM, en cambio, reescalan con $\mathbf{B}$ y no sufren por κ. SGD es la mejor opción cuando n es enorme (millones de datos), cada iteración de LM costaría demasiado y basta precisión moderada (aprendizaje automático).

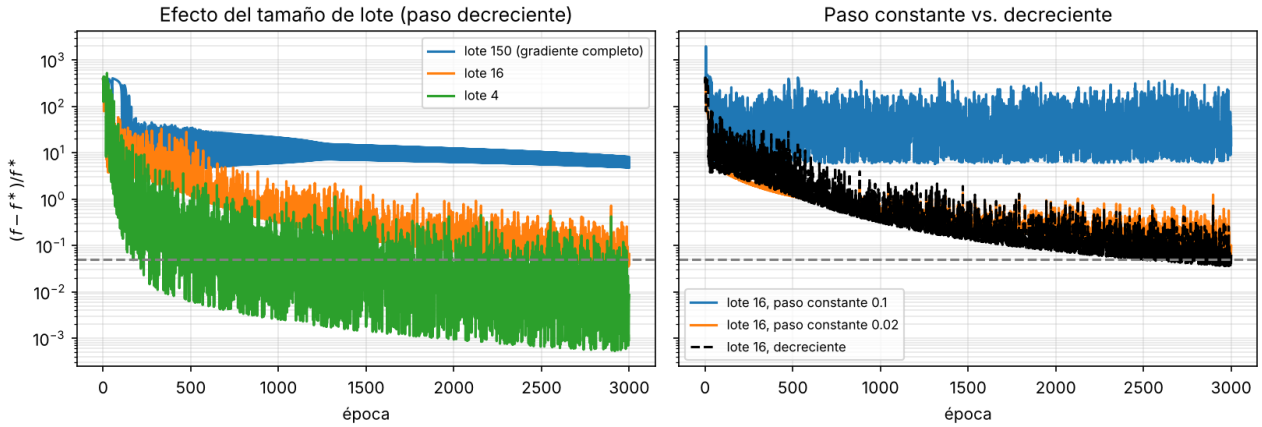


Figura 4: Efecto del lote (izquierda) y del paso (derecha).

Parte D: incertidumbre en $\boldsymbol{\theta}^*$

	a	b	c	d
$\boldsymbol{\theta}^*$	1.870	1.694	3.020	0.1471
desv. est.	0.050	0.101	0.032	0.0016
IC 95 % ($\pm 1.98\,\text{sd}$)	± 0.099	± 0.201	± 0.064	± 0.0031
error relativo (sd/valor)	2.7 %	6.0 %	1.1 %	1.1 %

Los cuatro valores verdaderos caen dentro de sus intervalos. Correlaciones: $\text{corr}(c, d) = 0.89$, $\text{corr}(b, c) = 0.67$, $\text{corr}(b, d) = 0.55$, $\text{corr}(a, c) = -0.44$, $\text{corr}(a, d) = -0.41$; $\kappa(\mathbf{J}^\top\mathbf{J}) = 2.1 \times 10^4$. La tasa rápida b es la peor determinada (error relativo 6 %) porque el transitorio rápido ocupa pocos minutos de $[0, 20]$ y solo unos pocos datos lo observan; c y d están fuertemente correlacionados porque un exceso de amplitud lenta se compensa con una tasa un poco mayor.

Efecto del ruido (mismos t_i, σ creciente):

σ	sd(a)	sd(b)	sd(c)	sd(d)
0.05	0.050	0.101	0.032	0.0016
0.2	0.209	0.501	0.112	0.0056
0.5	0.548	1.557	0.246	0.0127

Las desviaciones crecen aproximadamente $\propto \sigma$ ($\sigma \to 4\sigma$ multiplica sd(a) por 4.2). Para b crece *más* que proporcionalmente (sd pasa de 0.10 a 1.56 al multiplicar σ por 10) y la estimación se desplaza ($\hat{b} = 1.69, 2.17, 3.00$): con ruido alto la tasa rápida deja de ser identificable.

3. Puntos a revisar al calificar

- **Dogleg:** que no use el paso de Newton cuando $\mathbf{B}$ es singular (si lo hace, el modelo puede subir y $\rho_k < 0$ constante); que ρ_k use el modelo (no la función) en el denominador; que rechace el paso si $\rho_k \leq 0$.
- **LM:** escalado con diag($\mathbf{B}$) (las columnas de $\mathbf{J}$ difieren en varios órdenes de magnitud: $\partial r/\partial d \sim t$ crece con t); λ no puede crecer sin límite (parar por paso despreciable); relación $\lambda \uparrow \Leftrightarrow \Delta \downarrow$.
- **SGD:** que el gradiente del lote esté dividido por m (si no, α_0 depende del lote); que comparen por épocas o evaluaciones de datos, no por pasos.
- **C2:** que no concluyan "Dogleg es peor" sin diagnosticar el punto silla con la Hessiana exacta, y que no atribuyan el escape de LM a una garantía que no existe.
- **Variantes de datos:** cada estudiante tiene $\boldsymbol{\theta}_{\text{real}}$ distinto (± 10 %); los valores de este documento no coinciden con los suyos, pero las conclusiones cualitativas sí. Compara $\boldsymbol{\theta}^*$ con la tabla `verdad_parametros.csv`.

4. Cómo generar los datos de cada estudiante

```
python generar_datos.py 1017123456 1020333444 ...     # una semilla por documento
python generar_datos.py --lista documentos.txt        # uno por linea
```

Se crea `datos_estudiantes/datos_<doc>.csv` para cada uno y `verdad_parametros.csv` (no se entrega a los estudiantes).